


Análisis de Imágenes con Deep Learning

Superclass

aquatic mammals
fish
flowers
food containers
fruit and vegetables
household electrical devices
household furniture
insects
large carnivores
large man-made outdoor things
large natural outdoor scenes
large omnivores and herbivores
medium-sized mammals
non-insect invertebrates
people
reptiles
small mammals
trees
vehicles 1
vehicles 2

Classes

beaver, dolphin, otter, seal, whale
aquarium fish, flatfish, ray, shark, trout
orchids, poppies, roses, sunflowers, tulips
bottles, bowls, cans, cups, plates
apples, mushrooms, oranges, pears, sweet peppers
clock, computer keyboard, lamp, telephone, television
bed, chair, couch, table, wardrobe
bee, beetle, butterfly, caterpillar, cockroach
bear, leopard, lion, tiger, wolf
bridge, castle, house, road, skyscraper
cloud, forest, mountain, plain, sea
camel, cattle, chimpanzee, elephant, kangaroo
fox, porcupine, possum, raccoon, skunk
crab, lobster, snail, spider, worm
baby, boy, girl, man, woman
crocodile, dinosaur, lizard, snake, turtle
hamster, mouse, rabbit, shrew, squirrel
maple, oak, palm, pine, willow
bicycle, bus, motorcycle, pickup truck, train
lawn-mower, rocket, streetcar, tank, tractor



Objetivo

El objetivo de este reto es construir un sistema avanzado de clasificación de imágenes sobre el dataset CIFAR-100, aplicando técnicas de:

- visión clásica;
- CNNs;
- regularización;
- data augmentation;
- transfer learning;
- Optimización del entrenamiento.

A diferencia de CIFAR-10, este dataset presenta una dificultad significativamente mayor:

- 100 clases distintas;
- imágenes muy pequeñas (32×32);
- pocas muestras por clase;
- clases visualmente muy similares;
- alta confusión semántica.

El objetivo del reto será alcanzar: ***accuracy* ≥ 0.75** (sin overfitting significativo, por supuesto).

Contexto del reto

Hasta ahora, en el módulo, hemos trabajado:

- técnicas clásicas de procesamiento de imagen;
- convoluciones;
- filtros;
- histogramas;
- ecualización;
- segmentación;
- CNNs;
- data augmentation;
- regularización;
- transfer learning;
- arquitecturas profundas.

En este reto deberán combinarse ambos enfoques $\Rightarrow$ ***visión clásica + Deep Learning***.

¿Por qué CIFAR-100?

CIFAR-100 obliga a:

- regularizar correctamente;
- usar augmentation de forma seria;
- optimizar arquitecturas;
- analizar errores;
- controlar overfitting;
- comparar modelos rigurosamente.

Reto de Clasificación de Imágenes

Debes desarrollar un sistema de clasificación de imágenes usando CIFAR-100. Partirás de una CNN sencilla y deberás mejorarla progresivamente mediante diferentes estrategias. Se deberán entrenar y comparar al menos: **5 modelos distintos**.

Cada modelo deberá estar: justificado, evaluado, comparado y analizado.

Información del dataset

Propiedad	Valor
Número de clases	100
Resolución	32×32
Canales	RGB
Imágenes entrenamiento	50.000
Imágenes test	10.000
Imágenes por clase	Muy reducidas
Dificultad	Alta

Requisitos mínimos

El trabajo deberá incluir obligatoriamente:

1. Exploración del dataset

Debes analizar:

- número de clases;
- ejemplos visuales;
- dificultad aparente;
- clases similares;
- distribución del dataset.

2. Preprocesado

Aplicar como mínimo:

- normalización;
- separación train/validation/test;
- visualización de muestras;
- análisis visual del dataset.

3. Técnicas clásicas obligatorias

Debes probar al menos 3 técnicas clásicas distintas.

Ejemplos:

- CLAHE;
- ecualización;
- sharpening;
- Sobel;
- Laplaciano;
- Canny;
- filtros gaussianos;
- filtros medianos;
- mejora de contraste;
- edge enhancement;
- reducción de ruido.

Cada técnica deberá estar: explicada, justificada y evaluada. No basta con “aplicarla”.

Modelos Obligatorios

Modelo 1 — CNN base

CNN sencilla con:

- Conv2D;
- MaxPooling;
- Flatten;
- Dense;
- Softmax.

Objetivo: establecer un baseline.

Modelo 2 — CNN mejorada

Añadir mejoras como:

- Batch Normalization;
- Dropout;
- más profundidad;
- GlobalAveragePooling.

Modelo 3 — CNN + Data Augmentation

Aplicar augmentation:

- flips;
- rotations;
- crops;
- zoom;
- color jitter;
- brightness;
- random shifts.

Modelo 4 — CNN + técnicas clásicas

Entrenar usando imágenes modificadas mediante:

- ecualización;
- filtros;
- mapas de bordes;
- sharpening;
- pipelines híbridos.

Modelo 5 — Transfer Learning

Usar al menos un modelo preentrenado. Aquí tienes algunos ejemplos:

- ResNet;
- EfficientNet;
- MobileNet;
- DenseNet;
- ConvNeXt.

Ten en cuenta que en cada modelo, las imágenes deben redimensionarse: 96×96, 128×128, 224×224,...

Deberán probarse:

- freezing;
- fine tuning parcial;
- fine tuning profundo.

Técnicas avanzadas recomendadas

Se valorará positivamente el uso de:

- weight decay;
- label smoothing;
- cosine learning rate scheduling;
- early stopping;
- ReduceLROnPlateau;
- MixUp;
- CutMix;
- Random Erasing.

Evaluación obligatoria de cada modelo

Cada modelo deberá incluir:

- arquitectura;
- número de parámetros;
- accuracy train;
- accuracy validation;
- accuracy test;
- curvas de entrenamiento;
- matriz de confusión;
- classification report;
- análisis de errores;
- análisis de overfitting.

Control de overfitting

No gana necesariamente el modelo con más accuracy. Se evaluará:

$$\text{gap} = \text{train_accuracy} - \text{val_accuracy}$$

Referencias:

Gap	Interpretación
< 0.03	Excelente
0.03 – 0.07	Correcto
> 0.07	Posible overfitting
> 0.10	Overfitting claro

Prueba final con imágenes externas

Además del dataset original, deberán probarse, al menos, 5 imágenes externas. Las imágenes deberán pertenecer a clases presentes en CIFAR-100. Para cada imagen se deberá mostrar:

- imagen original;
- imagen redimensionada;
- predicción;
- probabilidades;

- top-5 predictions;
- análisis del resultado.

Tabla resumen obligatoria

Modelo	Técnicas usadas	Train acc	Val acc	Test acc	Gap	Comentarios
M1	CNN base					
M2	CNN + BN + Dropout					
M3	CNN + Augmentation					
M4	CNN + clásica					
M5	Transfer Learning					

Accuracy de referencia

Nivel	Accuracy
Básico	40% – 55%
Bueno	60% – 70%
Muy bueno	70% – 75%
Excelente	75% – 80%
Nivel competitivo	> 80%

Criterios de evaluación

Apartado	Peso
Exploración y análisis	10%
Uso de técnicas clásicas	15%
Desarrollo de modelos	25%
Evaluación rigurosa	20%

Control de overfitting	10%
Imágenes externas	10%
Claridad y conclusiones	10%

Sistema competitivo

La máxima nota se asignará al trabajo que consiga:

- mejor accuracy;
- mejor generalización;
- menor overfitting;
- mejor justificación técnica;
- mejor análisis de errores;
- mejor comparación entre modelos.

Un modelo con: 0.82 accuracy y fuerte overfitting puede quedar por debajo de otro con: 0.77 accuracy pero excelente generalización.

Entrega

- notebook `.ipynb` con gráficas y métricas.
- informe PDF.
- imágenes externas utilizadas;
- modelo final entrenado;

Conclusión esperada

El alumno deberá responder:

- ¿Qué modelo funcionó mejor?
- ¿Qué técnicas ayudaron realmente?
- ¿Qué clases generan más confusión?
- ¿Dónde falla el modelo?
- ¿Qué técnicas clásicas aportaron mejora?
- ¿El modelo generaliza correctamente?
- ¿Se alcanzó el objetivo de accuracy ≥ 0.75 ?